Index

- Streaming Video Instruction Tuning (Streamo)
- StreamEQA

Streaming Video Instruction Tuning (Streamo)

要解決的問題

- 多數的傳統LLM只支援離線影片，無法處理線上串流
- 而支援線上串流的LLM，又因為分成好幾個模型在處理，大幅增加回答問題的延遲，因此做不到影片及時互動，且對於多任務處理也不適應

Streamo的架構

3種 State Tokens

	當前狀態	模型行為
<Silence>	影片畫面沒有發生任何重要事件，或使用者沒有提出新問題	模型保持沉默，繼續接收與處理傳入的影格
<Standby>	影片中正在發生某個事件，但該事件尚未結束	模型偵測到與任務相關的影像輸入，保持待命並等待完整資訊傳入結束
<Response>	影片中的事件已經結束，或收到了使用者的提問	模型獲取足夠資訊，立即生成對應的回答

One-Pass Inference, Single Forward Pass

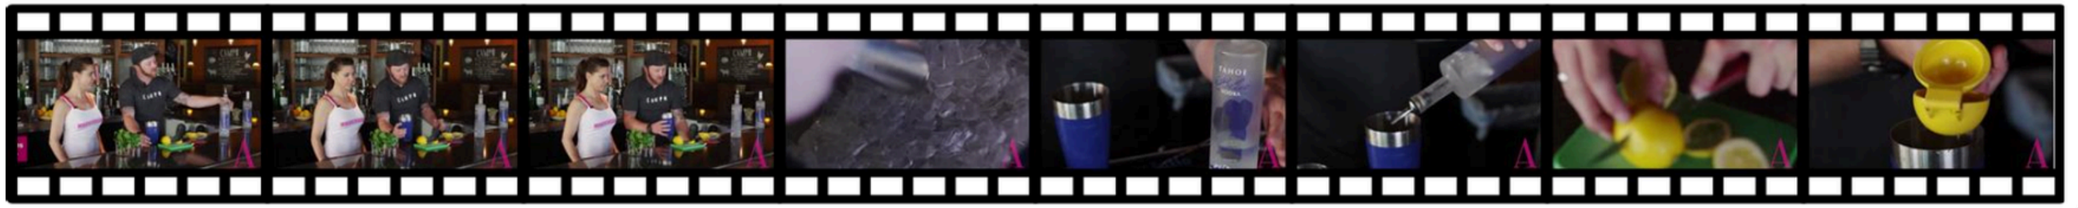
- 將所有事情(輸入、決策、輸出)合在同一個模型內完成，只需執行一次。
- 因為省去了多個模型間切換的傳輸，大幅減少了延遲，較符合real-time的互動

Streamo-Instruct-465K

用來訓練Streamo的資料集，包含了46.5萬的樣本，讓模型可以在同一支影片同時運行多個不同類型任務，並透過3種State Tokens去決定什麼時候要做什麼，任務主要可以分成五大類

Streaming Video Instruction Tuning (Streamo)

The video features a bartender demonstrating how to make a pink cocktail using ingredients like Tahoe Blue Vodka, lemon, mint, and a red mixer.



Real-time Narration

Narrate the video in real time, updating the description frame-by-frame or moment-by-moment as events unfold.

- Man picks up glass.
- Man places glass down.
- Man picked up a shaker.
- Hand shovels ice cubes.
- Camera focuses on bottle and shaker.
- Pouring liquid into the shaker.
- Lemon is cut in half.
- Lemon is squeezed.

Action Caption

Locate and pinpoint a sequential series of specific actions or steps in the video.

- <Silence>
- Man shovels some ice cubes into shaker
- Man pours some Vodka into the shaker
- Man cuts lemon.
- Man squeezes lemon.

Event Caption

Detect and summarize each event sequence in the video.

- The man begins to prepare the drink, while the woman watches.
- He fills a blue shaker tin with ice cubes, followed by pouring Tahoe Blue Vodka into the shaker.
- He then cuts lemons in half and squeezes fresh lemon juice into the shaker.

Event Grounding

Temporally localize the event: ‘Man added vodka to the shaker and squeezed in some lemon juice’. Respond once it has finished and summarize its time period.

- <Silence>
- Given event occurred between 34s to 50s.

Time-sensitive QA

What is the man currently holding in his hand.

- <Silence>
- shaker
- <Silence>
- glass
- knife
- squeezer

Streaming Video Instruction Tuning (Streamo)

LM Loss（Language Modeling Loss)

傳統的LM Loss

在訓練LLM時，根據前面已經出現的所有內容，讓模型去預測下一個最可能出現的內容。
透過Loss Function，如果模型的預測結果和實際結果不一樣，LM Loss的數值就會變大；預測得越準，LM Loss就越接近 0。
模型的目標就是透過不斷學習，把這個數值降到最低。

傳統的LM Loss的缺點

無論預測的是普通狀況還是特殊狀況，每個預測結果的權重都一樣。
所以長期下來，比起特殊狀況較多的普通狀況，會讓模型會把所有狀況都當作普通狀況來處理。

Focal-weighted LM Loss

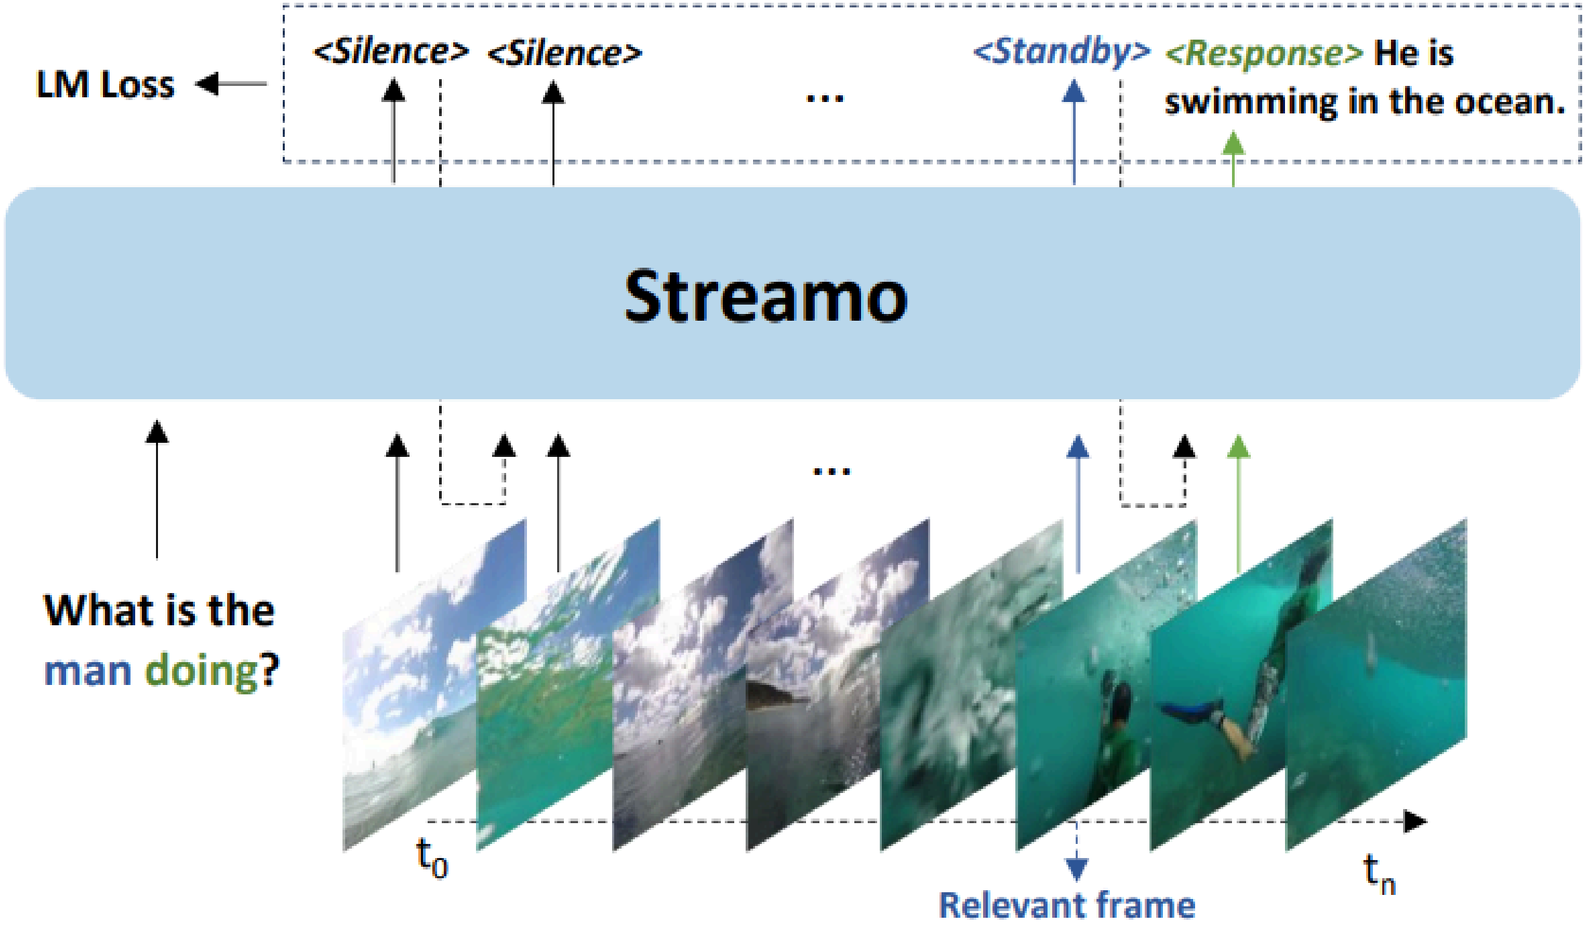
把普通狀況與特殊狀況的權重分開計算，把較容易預測的普通狀況權重給得較低，特殊狀況的權重給的較高，使模型強迫面對特殊狀況。

Streamo裡的LM Loss

- **傳統的LM Loss**：Silence出現的時間較多，而所有的token的權重皆一樣，模型會偏向一直猜Silence
- **Focal-weighted LM Loss**：容易預測的Silence的權重調低，強迫模型去預測較困難的Standby, Response。

Streaming Video Instruction Tuning (Streamo)

LM Loss (Language Modeling Loss)



Streamo與Video Streaming Thinking的比較

	Streamo	Video Streaming Thinking
適合環境	影片即時互動	影片長期記憶與整理
推論的架構	One-Pass Inference 將輸入、決策、輸出在單一模型內完成	Multi-Pass Inference 記憶、思考、決策、獎勵模型、輸出、...，都必須切換成不同的模型去運算
問題種類	較簡單的問題，描述關於影片中發生什麼事情或是做了什麼動作	較複雜的問題，可針對影片內發生的事情進行思考
追朔影片早期細節的問題	較容易忘掉先前內容	可透過長期記憶去回朔

StreamEQA

	傳統的影片LLM評測基準	StreamEQA
離線/線上	大多為離線影片 模型能在推理前取得完整預錄影片	線上串流 畫面像即時直播一樣連續輸入
視角	大多都是第三人稱通用問答或基礎感知，幾乎未著眼於具身智能所需的互動與規劃閉環	第一人稱 機器人或人類走動的具身真實場景
時間軸	沒有限制時間軸，模型可以作弊偷看後面時間軸所發生的事情	限制時間軸，提問當下，未來的畫面完全被遮蔽不可見

Task Taxonomy (StreamEQA)

Embodied Dimension

- **Perception**：辨識物體、動作、場景與空間關係
- **Interaction**：理解影片中的人與環境或工具的互動、狀態變化
- **Planning**：預測未來步驟或基於過去經驗進行決策推理

Streaming Dimension

- **Backward Reasoning**：檢驗模型對過去片段的長期記憶與檢索能力
- **Realtime Understanding**：檢驗模型對當前畫面發生的視覺狀態與操作細節是否能理解
- **Forward Prediction**：檢驗模型基於已知片段，對於未來事件的預測與推理能力

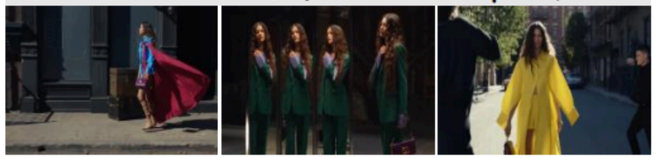
StreamEQA

不同種類的MLLMs

- **Offline Video QA**：看完整段離線影片，再回答使用者問題。
- **Embodied Video QA**：看完整段離線影片，再回答使用者問題，但引入了第一人稱視角。
- **Streaming Video QA**：即時、連續輸入的線上串流畫面，且部分過去畫面會隨時間淡出或被遮蔽，難度最高。

StreamEQA

Offline Video QA (Offline + Perception)



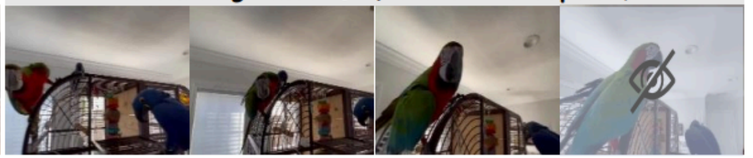
Q: What is the woman wearing when standing in front of the mirror?
A: A green suit with a purple blouse

Embodied Video QA (Offline + Planning/Intercation)



Q: What can I do to increase the speed of the ceiling fan?
A: Turn the dial on the switch panel next to the front door

Streaming Video QA (Online + Perception)



Q: What is the position of the red and green parrot relative to the blue parrot?
A: The red and green parrot is above the white parrot.

Perception/Interaction/Planning + Online

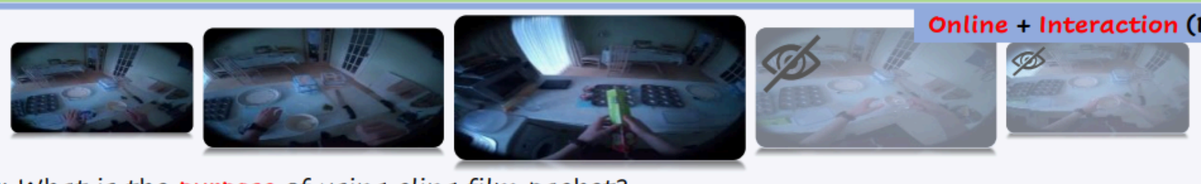
Past | Query Time | Future

Online + Perception (Backward)



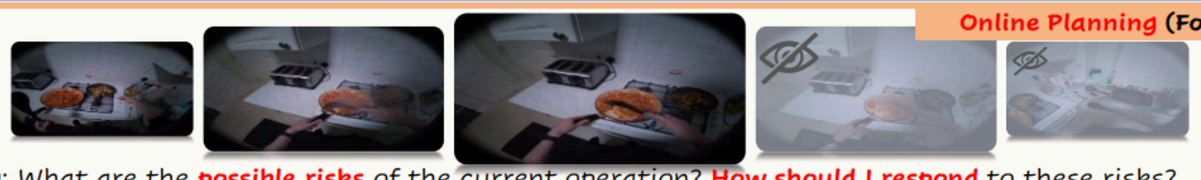
Q: What was the color of the bowl I saw just now?
A: White.

Online + Interaction (Realtime)



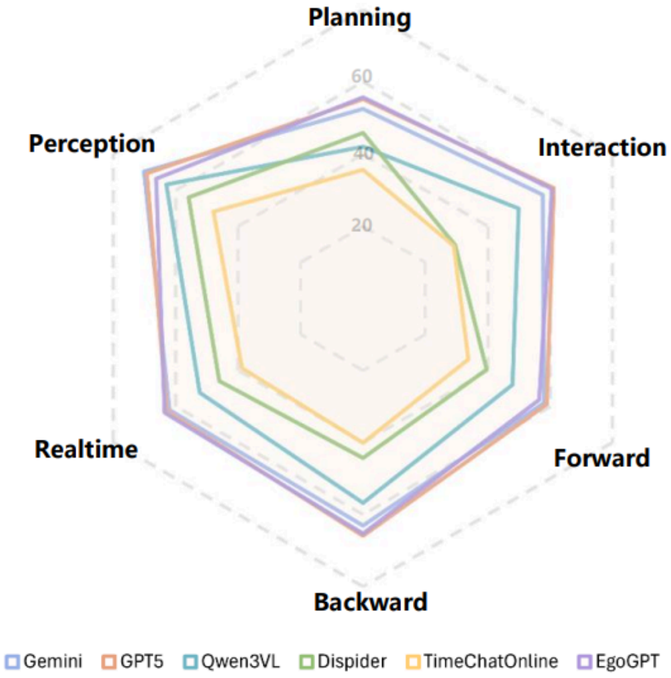
Q: What is the **purpose** of using cling film packet?
A: The cling film packet is opened to pull out cling film that will cover the bowl full of Yogurt.

Online Planning (Forward)



Q: What are the **possible risks** of the current operation? **How should I respond** to these risks?
A: Risks: Splashing hot tomato juices. Response: Lower heat and stir slowly.

StreamEQA
Online-Embodied Benchmark



StreamEQA

Data Construction Pipeline

Meta Information Extraction

- 讓較強的模型(VLM)去讀取影片的內容，並將影片內容的資訊進行統整

QA Construction

- 讓VLM將整理出來的資訊，透過問題的模板，生成問題(4選1選擇題)

Quality Control

- 增加題目難度：讓VLM針對每一題的3個錯誤選項進行修飾，使錯誤選項在敘述上更接近正確答案，以此誘惑答題的模型
- 人工驗證：由人類審查VLM所出的問題與答案是否合理

StreamEQA

Data Construction Pipeline

